

Filière Science de Données et Intelligence Artificielle

Rapport technique de projet de fin d'année

Développement d'un Système de Prédiction du Churn Client

Machine Learning avec XGBoost, CatBoost et Streamlit

Présenté le 14 juin 2026

Réalisé par :

Oumaima CHANNANI (4IASD)

Othmane AMINE (4IASD)

Encadré par :

– Prof. Oussama Elgerari

Année universitaire : 2025–2026

Résumé

La fidélisation des clients constitue un enjeu stratégique majeur pour les opérateurs de télécommunications, car l'acquisition d'un nouvel abonné est généralement plus coûteuse que la conservation d'un client existant. Ce projet a pour objectif de concevoir et de mettre en œuvre un système intelligent capable d'anticiper le churn client, d'expliquer les facteurs associés au risque de départ et de proposer des actions de fidélisation adaptées aux profils identifiés.

L'étude s'appuie sur un dataset télécom composé de 7043 clients et de 21 variables décrivant notamment leur profil, leur ancienneté, leur contrat, les services souscrits, leur méthode de paiement et leurs charges. Une chaîne de prétraitement reproductible a été développée afin de nettoyer les données, traiter les valeurs manquantes, convertir les variables numériques et encoder les attributs catégoriels. La séparation stratifiée en jeux d'entraînement (80 %) et de test (20 %) est effectuée avant l'ajustement du préprocesseur, ce qui limite les risques de fuite d'information et garantit une évaluation plus rigoureuse.

Trois modèles de classification ont été entraînés et comparés : XGBoost, CatBoost et la régression logistique. Leur performance a été mesurée avec l'Accuracy, la Precision, le Recall, le F1-score, le ROC-AUC et les matrices de confusion. Parmi les modèles de base, CatBoost obtient les meilleurs résultats globaux avec une Accuracy de 0,756, un Recall de 0,789, un F1-score de 0,632 et un ROC-AUC de 0,842. Une optimisation par validation croisée améliore ensuite le ROC-AUC test de XGBoost jusqu'à 0,847 et confirme la proximité des performances de XGBoost et CatBoost.

L'analyse exploratoire et l'étude de l'importance des variables montrent que le contrat mensuel, la faible ancienneté, les charges élevées, l'utilisation de la fibre optique, l'absence de support technique et le paiement par chèque électronique sont fortement associés au risque de churn. Ces résultats sont transformés en segments de risque faible, moyen ou élevé, puis en recommandations métier personnalisées, telles qu'un appel prioritaire, une remise ciblée ou une proposition de contrat annuel.

Enfin, les modèles et le préprocesseur sont intégrés dans une application et un dashboard Streamlit. Ces interfaces permettent respectivement d'obtenir une prédiction individuelle avec sa probabilité et d'analyser les tendances globales du portefeuille client. La solution proposée fournit ainsi un outil d'aide à la décision complet, interprétable et directement exploitable pour orienter les campagnes de fidélisation.

Mots-clés : churn client, télécommunications, machine learning, XGBoost, CatBoost, classification, feature importance, fidélisation, Streamlit.

Abstract

Customer retention is a major strategic concern for telecommunications companies, as acquiring a new subscriber is generally more expensive than retaining an existing customer. This project aims to design and implement an intelligent system capable of anticipating customer churn, explaining the main factors associated with departure risk, and recommending suitable retention actions for the identified customer profiles.

The study relies on a telecommunications dataset containing 7,043 customers and 21 variables describing customer profiles, tenure, contracts, subscribed services, payment methods, and charges. A reproducible preprocessing workflow was developed to clean the data, handle missing values, convert numerical attributes, and encode categorical features. A stratified 80/20 train-test split is performed before fitting the preprocessing components, reducing data leakage and ensuring a rigorous evaluation process.

Three classification models were trained and compared : XGBoost, CatBoost, and Logistic Regression. Their performance was assessed using Accuracy, Precision, Recall, F1-score, ROC-AUC, and confusion matrices. Among the baseline models, CatBoost achieved the best overall results, with an Accuracy of 0.756, a Recall of 0.789, an F1-score of 0.632, and a ROC-AUC of 0.842. Cross-validation-based hyperparameter optimization further increased XGBoost's test ROC-AUC to 0.847 and confirmed the close predictive performance of XGBoost and CatBoost.

Exploratory analysis and feature importance results indicate that month-to-month contracts, short tenure, high charges, fiber-optic Internet service, lack of technical support, and electronic check payments are strongly associated with churn risk. The predicted probabilities are converted into low, medium, and high-risk segments and linked to personalized business recommendations, including priority calls, targeted discounts, and annual contract offers.

Finally, the trained models and preprocessing pipeline are integrated into a Streamlit prediction application and an analytical dashboard. These interfaces support both individual churn prediction and portfolio-level analysis. The resulting solution provides a complete, interpretable, and operational decision-support tool for improving customer retention strategies.

Keywords : customer churn, telecommunications, machine learning, XGBoost, CatBoost, classification, feature importance, customer retention, Streamlit.

Table des matières

Liste des figures	4
Liste des tableaux	5
Introduction générale	6
1 Informations Générales	7
1.1 Contexte et problématique	7
1.2 Objectifs	7
1.3 Architecture de la solution	7
1.4 Démarche méthodologique	8
2 Chapitre 1 : Prétraitement et analyse exploratoire	8
2.1 Présentation du dataset	8
2.2 Description des groupes de variables	9
2.3 Diagnostic de qualité des données	9
2.4 Nettoyage, imputation et encodage	9
2.5 Prévention des fuites de données	10
2.6 Principaux résultats de l'analyse exploratoire	10
2.7 Interprétation métier de l'analyse exploratoire	10
3 Chapitre 2 : Entraînement et évaluation des modèles	11
3.1 Formulation du problème	11
3.2 Modèles et protocole d'entraînement	11
3.3 Définition des métriques	11
3.4 Métriques d'évaluation	12
3.5 Optimisation des hyperparamètres	13
3.6 Choix du modèle et limites de l'évaluation	13
4 Chapitre 3 : Interprétation et recommandations métier	14
4.1 Objectif de l'interprétabilité	14
4.2 Analyse de feature importance	14
4.3 Lecture croisée des modèles	15
4.4 Segmentation du risque	15
4.5 Recommandations de fidélisation	16
4.6 Mise à disposition avec Streamlit	16
4.7 Parcours utilisateur et architecture de déploiement	16
4.8 Suivi opérationnel recommandé	17
Conclusion générale	18
Bibliographie	19
5 Annexes	20
5.1 Structure du repository	20
5.2 Commandes d'exécution	20

Table des figures

1	Matrice de confusion et courbe ROC du modèle CatBoost	12
2	*	14
3	*	14
4	Variables les plus influentes selon les modèles	14

Liste des tableaux

1	Résumé du dataset	8
2	Organisation fonctionnelle des variables	9
3	Taux de churn par catégorie	10
4	Interprétation des métriques d'évaluation	12
5	Performances sur le jeu de test	12
6	Meilleurs hyperparamètres identifiés	13
7	Résultats après optimisation	13
8	Synthèse des facteurs de risque et interprétation métier	15
9	Recommandations automatisées par segment	16

Introduction générale

La transformation numérique des entreprises a considérablement augmenté la quantité de données disponibles sur les comportements et les usages des clients. Dans le secteur des télécommunications, chaque interaction laisse des traces exploitables : durée de la relation, services activés, type de contrat, mode de paiement, facturation et historique des charges. L'analyse de ces informations permet de mieux comprendre les attentes des abonnés et d'anticiper les situations susceptibles de conduire à une résiliation.

Le churn client représente la perte d'un abonné au profit d'un concurrent ou à la suite d'une interruption volontaire du service. Son impact dépasse la simple diminution du nombre de clients. Il peut entraîner une baisse du revenu récurrent, une augmentation des dépenses commerciales et une dégradation de la valeur vie client. Une stratégie uniquement réactive intervient souvent trop tard. À l'inverse, un système prédictif peut hiérarchiser les clients selon leur niveau de risque et permettre aux équipes métier d'agir avant la résiliation.

La problématique étudiée dans ce rapport est donc la suivante :

Comment construire un système de machine learning fiable, interprétable et exploitable permettant de prédire le churn client et de transformer les résultats du modèle en actions de fidélisation concrètes ?

Pour répondre à cette problématique, le projet met en place une démarche complète. Elle débute par l'analyse et la préparation d'un dataset télécom, puis compare plusieurs modèles de classification supervisée. Les performances sont évaluées selon plusieurs métriques afin de ne pas limiter l'analyse à l'Accuracy, particulièrement insuffisante lorsque les classes sont déséquilibrées. L'interprétation des variables influentes complète cette évaluation et permet de relier les résultats statistiques à des décisions métier.

Le rapport est organisé en trois chapitres principaux. Le premier présente les données, leur qualité, le prétraitement et les enseignements de l'analyse exploratoire. Le deuxième détaille le protocole expérimental, les modèles, leurs métriques et l'optimisation des hyperparamètres. Le troisième traite de l'interprétation, de la segmentation du risque, des recommandations de fidélisation et de l'intégration dans Streamlit. Une conclusion générale synthétise enfin les apports, les limites et les perspectives du projet.

1 Informations Générales

1.1 Contexte et problématique

Le churn client désigne la décision d'un abonné de quitter un service. Dans le secteur des télécommunications, cette situation entraîne une perte de revenu et un coût d'acquisition supplémentaire pour remplacer le client. L'objectif du projet est de détecter les clients susceptibles de résilier leur abonnement afin de déclencher une action de fidélisation adaptée.

Information


Le système développé couvre toute la chaîne de valeur : préparation des données, analyse exploratoire, entraînement et comparaison des modèles, interprétation des prédictions, recommandations métier et mise à disposition dans une application Streamlit.

1.2 Objectifs

Les objectifs techniques et métier du projet sont les suivants :

- construire un pipeline reproductible de nettoyage, d'imputation et d'encodage des données ;
- entraîner XGBoost et CatBoost, puis les comparer à une régression logistique de référence ;
- évaluer les modèles avec Accuracy, Precision, Recall, F1-score, ROC-AUC et matrices de confusion ;
- identifier les variables qui influencent le plus le churn ;
- fournir une probabilité de churn et une recommandation de fidélisation dans une interface Streamlit.

1.3 Architecture de la solution



L'organisation modulaire sépare le prétraitement (`src/preprocessing.py`), l'entraînement (`src/training.py`), la prédiction (`src/prediction.py`) et les recommandations métier (`src/retention.py`).

1.4 Démarche méthodologique

La démarche adoptée suit un cycle de développement proche de CRISP-DM : compréhension du besoin métier, compréhension et préparation des données, modélisation, évaluation, interprétation et mise à disposition. Chaque étape produit un livrable vérifiable : données transformées, modèles sauvegardés, métriques, graphiques, tests automatisés et interfaces utilisateur.

Le choix d'une architecture modulaire facilite la reproductibilité. Le script `train_and_evaluate.py` orchestre le pipeline complet, tandis que le préprocesseur sauvegardé garantit que les transformations appliquées lors de l'inférence sont identiques à celles apprises pendant l'entraînement.

2 Chapitre 1 : Prétraitement et analyse exploratoire

2.1 Présentation du dataset

Dataset

Le fichier `data/WA_Fn-UseC_-Telco-Customer-Churn.csv` contient **7 043 clients** et **21 colonnes**. La cible **Churn** indique si un client a quitté le service.

TABLE 1 – Résumé du dataset

Indicateur	Valeur
Nombre de clients	7 043
Clients fidèles	5 174 (73,46 %)
Clients ayant churné	1 869 (26,54 %)
Ancienneté moyenne	32,37 mois
Charges mensuelles moyennes	64,76
Valeurs manquantes dans <code>TotalCharges</code>	11
Doublons détectés	0

Les variables décrivent le profil du client, son ancienneté, son contrat, les services souscrits, son mode de paiement et ses charges. La variable `customerID` sert uniquement d'identifiant et n'est pas utilisée pour l'apprentissage.

2.2 Description des groupes de variables

TABLE 2 – Organisation fonctionnelle des variables

Groupe	Variables et rôle analytique
Profil client	<code>gender</code> , <code>SeniorCitizen</code> , <code>Partner</code> et <code>Dependents</code> décrivent les principales caractéristiques du foyer.
Relation commerciale	<code>tenure</code> mesure l'ancienneté et <code>Contract</code> précise le niveau d'engagement du client.
Services souscrits	Téléphonie, Internet, sécurité, sauvegarde, protection, support technique et streaming décrivent la composition de l'offre.
Facturation et paiement	<code>PaperlessBilling</code> , <code>PaymentMethod</code> , <code>MonthlyCharges</code> et <code>TotalCharges</code> décrivent la relation financière.
Variable cible	<code>Churn</code> indique si le client a quitté le service.

2.3 Diagnostic de qualité des données

Le diagnostic initial vérifie la dimension du dataset, les types de données, les doublons, les valeurs manquantes et la cohérence de la cible. Aucun doublon complet n'est observé. En revanche, 11 valeurs de `TotalCharges` sont vides. Elles concernent généralement des clients très récents pour lesquels le montant total n'a pas encore été renseigné. La conversion numérique transforme ces chaînes vides en valeurs manquantes avant leur imputation.

La cible est déséquilibrée : 26,54 % des clients ont churné contre 73,46 % de clients fidèles. Ce déséquilibre reste modéré, mais il justifie l'utilisation d'un split stratifié, d'une pondération de classe et de métriques complémentaires à l'Accuracy.

2.4 Nettoyage, imputation et encodage

Le prétraitement est implémenté dans `src/preprocessing.py`. Les opérations réalisées sont :

1. suppression des espaces dans les noms de colonnes et les chaînes ;
2. suppression des doublons et de l'identifiant `customerID` ;
3. conversion des variables numériques, notamment `TotalCharges`, avec transformation des valeurs invalides en valeurs manquantes ;
4. imputation médiane des variables numériques ;
5. imputation par la modalité la plus fréquente pour les variables catégorielles ;
6. encodage One-Hot des variables catégorielles, avec gestion des nouvelles catégories grâce à `handle_unknown=ignore`.

Point de vigilance

La séparation Train/Test est réalisée avant l'ajustement de l'imputation et de l'encodage. Le préprocesseur est ajusté uniquement sur le jeu d'entraînement, ce qui évite une fuite d'information provenant du jeu de test.

Le split est stratifié selon la cible avec un état aléatoire fixé à 42. Il produit **5 634 observations d'entraînement** (79,99 %) et **1 409 observations de test** (20,01 %). Après encodage, chaque client est représenté par 40 variables.

2.5 Prévention des fuites de données

Une fuite de données apparaît lorsqu'une information indisponible au moment de la prédiction influence l'apprentissage. Pour l'éviter, le projet sépare d'abord les observations en jeux Train et Test. Les statistiques d'imputation et les catégories du One-Hot Encoding sont ensuite apprises uniquement sur Train. Le jeu Test est transformé avec ces paramètres sans nouvel ajustement.

Cette règle est également appliquée dans Streamlit : les profils saisis ne créent jamais un nouveau préprocesseur. Ils sont transformés à l'aide du fichier `models/preprocessor.pkl`, puis transmis au modèle sélectionné.

2.6 Principaux résultats de l'analyse exploratoire

L'analyse exploratoire met en évidence plusieurs profils particulièrement exposés au churn :

TABLE 3 – Taux de churn par catégorie

Catégorie	Taux de churn
Contrat mensuel	42,71 %
Contrat d'un an	11,27 %
Contrat de deux ans	2,83 %
Internet fibre optique	41,89 %
Internet DSL	18,96 %
Sans service Internet	7,40 %
Paieement par chèque électronique	45,29 %
Facturation sans papier	33,57 %

Les clients ayant churné ont une ancienneté moyenne de **17,98 mois**, contre **37,57 mois** pour les clients fidèles. Leurs charges mensuelles moyennes sont également plus élevées : **74,44** contre **61,27**. Ces observations suggèrent que les nouveaux clients, les contrats sans engagement, la fibre optique et les paiements électroniques doivent faire l'objet d'un suivi prioritaire.

2.7 Interprétation métier de l'analyse exploratoire

L'écart observé entre les contrats mensuels et les contrats de longue durée montre que l'engagement contractuel constitue un facteur majeur de stabilité. Le taux élevé associé à la fibre optique peut refléter des attentes plus fortes sur la qualité de service ou un niveau tarifaire plus élevé. Le paiement par chèque électronique et la facturation sans papier identifient également un segment dont le comportement mérite une analyse complémentaire.

Ces constats guident la modélisation sans être considérés comme des relations causales. Ils servent à formuler des hypothèses, à vérifier la cohérence des variables importantes et à préparer les futures recommandations métier.

3 Chapitre 2 : Entraînement et évaluation des modèles

3.1 Formulation du problème

La prédiction du churn est formulée comme une classification binaire. Pour chaque client décrit par un vecteur de caractéristiques x , le modèle estime une probabilité $P(Y = 1 \mid x)$, où $Y = 1$ représente le churn et $Y = 0$ la fidélité. La classe prédite dépend ensuite d'un seuil de décision, fixé à 50 % pour l'évaluation standard.

L'objectif n'est pas uniquement de produire une classe, mais aussi un score de risque permettant de prioriser les actions. Une probabilité continue est plus utile qu'une réponse binaire pour organiser les campagnes de rétention et adapter leur intensité.

3.2 Modèles et protocole d'entraînement

Trois modèles de classification sont entraînés afin de comparer différentes familles d'algorithmes :

- **XGBoost**, avec 200 arbres, une profondeur maximale de 5 et un taux d'apprentissage de 0,1 ;
- **CatBoost**, avec 300 itérations, une profondeur de 6 et un taux d'apprentissage de 0,05 ;
- **Régression logistique**, utilisée comme modèle de référence interprétable.

Le déséquilibre de la cible est pris en compte avec une pondération renforcée de la classe churn. Tous les modèles sont évalués sur le même jeu de test stratifié, jamais utilisé pendant leur entraînement.

XGBoost est retenu pour sa capacité à modéliser des interactions non linéaires et pour son efficacité sur des données tabulaires [1]. CatBoost constitue une seconde approche de gradient boosting conçue pour réduire certains biais d'apprentissage et traiter efficacement les variables catégorielles [2]. La régression logistique fournit une référence plus simple et facilite la comparaison avec une frontière de décision linéaire.

3.3 Définition des métriques

Les métriques sont calculées à partir des vrais positifs (VP), faux positifs (FP), vrais négatifs (VN) et faux négatifs (FN) :

$$\begin{aligned} \text{Accuracy} &= \frac{VP + VN}{VP + VN + FP + FN}, \\ \text{Precision} &= \frac{VP}{VP + FP}, \\ \text{Recall} &= \frac{VP}{VP + FN}, \\ \text{F1-score} &= 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \end{aligned}$$

TABLE 4 – Interprétation des métriques d'évaluation

Métrique	Interprétation dans le contexte du churn
Accuracy	Part totale des clients correctement classés.
Precision	Part des alertes churn correspondant réellement à des churners.
Recall	Part des churners réels détectés par le modèle.
F1-score	Compromis entre la Precision et le Recall.
ROC-AUC	Capacité du modèle à classer un churning au-dessus d'un client fidèle pour différents seuils [4].

Dans ce projet, le Recall et le ROC-AUC occupent une place importante. Un Recall élevé limite les clients à risque non détectés, tandis que le ROC-AUC évalue la qualité du classement indépendamment d'un seuil unique.

3.4 Métriques d'évaluation

TABLE 5 – Performances sur le jeu de test

Modèle	Accuracy	Precision	Recall	F1-score	ROC-AUC
XGBoost	0,750	0,521	0,735	0,610	0,828
CatBoost	0,756	0,527	0,789	0,632	0,842
Régression logistique	0,740	0,506	0,783	0,615	0,841

CatBoost obtient les meilleurs scores globaux avec un ROC-AUC de 0,842 et un recall de 0,789. Ce recall signifie que le modèle identifie environ 79 % des clients qui quittent réellement le service. Ce critère est important dans le contexte métier, car un faux négatif correspond à un client à risque qui ne recevra aucune action de fidélisation.

La Precision reste proche de 0,52 pour les modèles de boosting. Cette valeur indique qu'une partie significative des clients ciblés ne churnera pas réellement. Ce compromis est cohérent avec la pondération renforcée de la classe positive : le modèle accepte davantage de faux positifs afin de détecter plus de churners. Le choix final doit donc dépendre du coût d'une campagne de fidélisation par rapport au coût de perte d'un client.




FIGURE 1 – Matrice de confusion et courbe ROC du modèle CatBoost

3.5 Optimisation des hyperparamètres

Une optimisation complémentaire est réalisée avec `RandomizedSearchCV` pour XGBoost et CatBoost, et `GridSearchCV` pour la régression logistique. La métrique optimisée est le ROC-AUC.

La recherche aléatoire explore différentes combinaisons du nombre d'arbres, de la profondeur, du taux d'apprentissage et des paramètres d'échantillonnage. La validation croisée estime la stabilité des configurations sur plusieurs sous-ensembles du jeu d'entraînement. Le jeu Test reste réservé à l'évaluation finale.

TABLE 6 – Meilleurs hyperparamètres identifiés

Modèle	Configuration retenue
XGBoost	200 arbres, profondeur 3, taux d'apprentissage 0,05, sous-échantillonnage 0,7, <code>colsample_bytree=0,7</code> et <code>min_child_weight=5</code> .
CatBoost	200 itérations, profondeur 4, taux d'apprentissage 0,05 et <code>12_leaf_reg=7</code> .
Régression logistique	$C = 10$ avec le solveur <code>lbfgs</code> .

TABLE 7 – Résultats après optimisation

Modèle	ROC-AUC validation croisée	ROC-AUC test
XGBoost optimisé	0,850	0,847
CatBoost optimisé	0,851	0,847
Régression logistique optimisée	0,846	0,840

L'optimisation améliore notamment le ROC-AUC test de XGBoost, qui passe de 0,828 à 0,847. Les modèles, le préprocesseur et les résultats sont sauvegardés dans le dossier `models/` au format `.pkl`, `.csv` et `.png`.

3.6 Choix du modèle et limites de l'évaluation

CatBoost est retenu comme meilleur modèle de base, car il obtient le meilleur Recall, le meilleur F1-score et le meilleur ROC-AUC. Après optimisation, XGBoost et CatBoost atteignent des performances très proches. Le choix de production peut donc intégrer d'autres critères : temps d'inférence, facilité de maintenance, stabilité des scores et coût des erreurs.

L'évaluation actuelle repose sur une séparation unique Train/Test issue d'un dataset historique. Elle ne mesure pas encore la dérive temporelle, les changements de comportement ou l'impact réel des actions commerciales. Une validation sur des périodes futures serait nécessaire avant une utilisation opérationnelle à grande échelle.

4 Chapitre 3 : Interprétation et recommandations métier

4.1 Objectif de l'interprétabilité

Un score prédictif n'est réellement utile que s'il peut être compris et relié à une décision. L'interprétabilité permet de vérifier que le modèle s'appuie sur des variables cohérentes, d'identifier les populations prioritaires et de formuler des actions de fidélisation. Elle contribue également à détecter des biais potentiels ou des dépendances excessives à certaines caractéristiques.

4.2 Analyse de feature importance

L'importance des variables permet de comprendre les facteurs utilisés par les modèles. Pour XGBoost, la variable dominante est le contrat mensuel, suivie du service Internet par fibre optique. Pour CatBoost, l'ancienneté, les charges totales et les charges mensuelles occupent les premières positions.




FIGURE 2 – *
XGBoost




FIGURE 3 – *
CatBoost

FIGURE 4 – Variables les plus influentes selon les modèles

Les facteurs récurrents entre l'analyse exploratoire et les modèles sont :

- le contrat mensuel, fortement associé au churn ;
- une faible ancienneté ;
- des charges mensuelles et totales élevées ;
- la fibre optique ;
- l'absence de support technique ou de sécurité en ligne ;
- le paiement par chèque électronique.

Point de vigilance

La feature importance décrit l'influence d'une variable sur la prédiction, mais ne prouve pas une relation causale. Les actions métier doivent donc être validées par des tests contrôlés et un suivi de leur efficacité.

4.3 Lecture croisée des modèles

Les importances ne sont pas directement comparables en valeur absolue entre XGBoost, CatBoost et la régression logistique, car chaque algorithme les calcule différemment. Leur classement permet toutefois d'identifier des facteurs récurrents. Le contrat, l'ancienneté, les charges et le service Internet apparaissent à la fois dans l'analyse exploratoire et dans les trois familles de modèles.

TABLE 8 – Synthèse des facteurs de risque et interprétation métier

Facteur	Interprétation et piste d'action
Contrat mensuel	Faible engagement ; proposer un avantage conditionné à un contrat annuel.
Faible ancienneté	Phase d'adoption sensible ; renforcer l'accompagnement des nouveaux clients.
Charges élevées	Risque de perception négative du rapport qualité-prix ; effectuer une revue de facture ou proposer une offre adaptée.
Fibre optique	Attentes potentiellement élevées ; surveiller la qualité et la satisfaction.
Absence de support	Risque de frustration non résolue ; promouvoir ou offrir temporairement l'assistance technique.

4.4 Segmentation du risque

Chaque probabilité produite par le modèle est transformée en un niveau de risque directement exploitable :

- **risque faible** : probabilité inférieure à 30 % ;
- **risque moyen** : probabilité entre 30 % et 60 % ;
- **risque élevé** : probabilité supérieure ou égale à 60 %.

La segmentation combine ensuite le score avec l'ancienneté, le montant des charges et le type de contrat. Elle distingue notamment les clients à forte valeur, les nouveaux clients vulnérables et les clients sans engagement à convertir.

Le seuil de 60 % permet d'identifier les clients nécessitant une intervention rapide, tandis que le niveau moyen sert à déclencher des actions préventives moins coûteuses. Ces seuils constituent des règles métier initiales. Ils devraient être optimisés à partir du coût des campagnes, de la valeur client et du taux de succès des actions.

4.5 Recommandations de fidélisation

TABLE 9 – Recommandations automatisées par segment

Segment	Action recommandée
Forte valeur à risque	Appel prioritaire sous 24 heures, remise personnalisée et revue de facture.
Nouveau client vulnérable	Renforcer l'accueil, réaliser un appel de satisfaction et offrir une assistance.
Sans engagement à convertir	Proposer un contrat annuel avec remise et avantage de fidélité.
Client à surveiller	Envoyer une enquête de satisfaction et une offre ciblée.
Client fidèle à valoriser	Valoriser l'ancienneté et proposer un avantage exclusif.
Client stable	Maintenir la relation standard et suivre régulièrement la satisfaction.

4.6 Mise à disposition avec Streamlit

L'application principale `app.py` permet de saisir le profil d'un client, de choisir un modèle et d'obtenir :

- une prédiction Churn ou No Churn ;
- la probabilité estimée de churn ;
- le segment de risque et une recommandation personnalisée ;
- les métriques, courbes ROC et importances de variables.

Le dashboard `Bonus/dashboard_analytics.py` fournit une vue agrégée avec filtres, indicateurs de churn, revenu à risque, graphiques analytiques et table des clients à risque élevé.

Information

Le même préprocesseur sauvegardé lors de l'entraînement est réutilisé pour les prédictions Streamlit. Cette cohérence garantit que les données saisies suivent exactement les transformations apprises pendant l'entraînement.

4.7 Parcours utilisateur et architecture de déploiement

Dans l'application principale, l'utilisateur sélectionne un modèle et renseigne les informations du client dans la barre latérale. Le formulaire est transformé par le préprocesseur sauvegardé, puis transmis au modèle afin de produire une classe et une probabilité. Le résultat est enrichi par le module de rétention avant d'être affiché avec les métriques et les graphiques d'analyse.

Le dashboard analytique applique le même principe sur un ensemble de clients. Il permet de filtrer le portefeuille, de calculer les scores de risque et de suivre les indicateurs de churn. La séparation entre logique de préparation, modélisation, prédiction et interface réduit la duplication et facilite les évolutions futures.

4.8 Suivi opérationnel recommandé

Une mise en production durable nécessite un suivi régulier :

- contrôler la distribution des variables et la dérive des scores ;
- suivre le Recall, la Precision et le ROC-AUC sur les nouvelles périodes ;
- mesurer le taux d'acceptation et l'efficacité des recommandations ;
- recalibrer les seuils selon les coûts et la capacité des équipes ;
- réentraîner le modèle lorsque les performances se dégradent.

Conclusion générale

Ce projet a permis de concevoir une solution complète de prédiction du churn client, depuis l'analyse des données jusqu'à la mise à disposition des résultats dans une interface interactive. Le pipeline développé assure le nettoyage, l'imputation, l'encodage et la séparation rigoureuse des données. La réutilisation du préprocesseur pendant l'inférence garantit la cohérence entre l'entraînement et les prédictions réalisées dans Streamlit.

La comparaison de XGBoost, CatBoost et de la régression logistique montre que les approches étudiées offrent une bonne capacité de classement. CatBoost obtient les meilleurs résultats parmi les modèles de base, avec un ROC-AUC de 0,842 et un Recall de 0,789. L'optimisation des hyperparamètres améliore notamment XGBoost jusqu'à un ROC-AUC test de 0,847. Ces résultats confirment l'intérêt du gradient boosting pour l'analyse de données clients tabulaires.

Au-delà de la performance prédictive, l'analyse exploratoire et la feature importance ont permis d'identifier les principaux facteurs associés au churn : contrat mensuel, faible ancienneté, charges élevées, fibre optique et absence de certains services d'assistance. Le système transforme ces informations en segments de risque et en recommandations de fidélisation directement exploitables.

La solution présente néanmoins plusieurs limites. Le dataset ne contient pas d'historique temporel détaillé, d'informations sur les interactions avec le service client ni de mesure du résultat des campagnes de rétention. De plus, les importances de variables ne permettent pas d'établir une causalité. Une validation métier reste donc indispensable avant toute automatisation des décisions.

Les perspectives prioritaires consistent à intégrer des données plus récentes, mettre en place une surveillance de dérive, calibrer les probabilités, optimiser le seuil selon la valeur économique des clients et évaluer les recommandations par des tests A/B. Une telle évolution permettrait de passer d'un prototype prédictif à un véritable système continu d'aide à la décision.

Bibliographie

Références

- [1] T. Chen et C. Guestrin, *XGBoost : A Scalable Tree Boosting System*, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.
- [2] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush et A. Gulin, *CatBoost : Unbiased Boosting with Categorical Features*, Advances in Neural Information Processing Systems, 2018.
- [3] F. Pedregosa et al., *Scikit-learn : Machine Learning in Python*, Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.
- [4] T. Fawcett, *An Introduction to ROC Analysis*, Pattern Recognition Letters, vol. 27, no. 8, pp. 861–874, 2006.
- [5] Streamlit, *Streamlit Documentation*, <https://docs.streamlit.io/>, consulté en juin 2026.
- [6] XGBoost Developers, *XGBoost Documentation*, <https://xgboost.readthedocs.io/>, consulté en juin 2026.
- [7] CatBoost Developers, *CatBoost Documentation*, <https://catboost.ai/>, consulté en juin 2026.

5 Annexes

5.1 Structure du repository

```
churn_project/
|-- data/                Dataset CSV
|-- notebooks/          EDA et expérimentations
|-- src/                Prétraitement, entraînement et prédiction
|-- models/             Modèles et résultats sauvegardés
|-- Bonus/              Dashboard, API et optimisation
|-- tests/              Tests automatisés
|-- app.py              Application Streamlit
|-- train_and_evaluate.py Pipeline d'entraînement
'-- requirements.txt     Dépendances Python
```

5.2 Commandes d'exécution

```
python -m pip install -r requirements.txt
python train_and_evaluate.py
python Bonus/hyperparameter_tuning.py --quick
python -m streamlit run app.py
python -m streamlit run Bonus/dashboard_analytics.py
python -m pytest -q
```